

Proyecto Final: Triage de tickets de soporte con AI

1. Introducción

Este documento presenta el análisis de costos del sistema de triage de tickets, justificando la elección de modelos de IA por tarea y calculando el ahorro mediante Prompt Caching y Message Batches API.

2. Comparativa de Modelos de IA

Modelo	Proveedor	Input/1M tokens	Output/1M tokens	Ideal para
GPT-4o-mini	OpenAI	\$0.15	\$0.60	Clasificación, tareas simples
GPT-4o	OpenAI	\$2.50	\$10.00	Tareas complejas
Claude Sonnet 5	Anthropic	\$2.00	\$10.00	Razonamiento, documentos
Claude Haiku 4.5	Anthropic	\$1.00	\$5.00	Tareas rápidas
Claude Opus 5	Anthropic	\$5.00	\$25.00	Alta complejidad

En mi caso, utilizo GPT-4o-mini para todas las tareas del flujo porque son tareas de clasificación y generación de respuestas cortas. No necesito razonamiento complejo. Utilizar GPT-4o-mini me genera un ahorro del 94% en comparación a utilizar GPT-4o.

3. Cálculo con batches

Si proceso 1,000 tickets al mes agrupados en lotes (Batch):

Concepto	Sin Batch	Con Batch (50% off)
Costo input	\$0.075	\$0.0375

Costo output	\$0.12	\$0.06
Total/mes	\$0.195	\$0.0975
Ahorro	—	50%

Nota: El Batch API tiene hasta 24 horas de latencia. Para tickets urgentes, uso llamadas normales. Para análisis masivos (ej. reportes semanales), uso Batch.

4. Costos de Make

Componente	Créditos/mes	Plan
Flujo 1 (5 módulos × 1,000 tickets)	5,000	Core
Flujo 2 (2 módulos × 500 aprobados)	1,000	Core
Total	6,000	Core (\$9/mes)

5. Conclusión

El sistema es extremadamente económico: \$9.10 USD/mes para procesar 1,000 tickets. El uso de GPT-4o-mini en lugar de modelos premium reduce el costo de IA en ~94%, y el Message Batches API lo reduce otro 50% para procesos no urgentes.